

MACHINE LEARNING

LESSON 1: Introduction

CARSTEN EIE FRIGAARD HENRIK DANIEL KJELDSEN





Undervisere

Carsten Eie Frigaard:

kursusholder,

rum: E311,

email: cef@ase.au.dk

Henrik Daniel Kjeldsen:

kursusholder,

rum: E301,

email: hdk@ase.au.dk

Peter Ahrendt hjælpelærer,

rum: E308,

email: pah@ase.au.dk







Litteratur

"Hands-On Machine Learning with Scikit-Learn and TensorFlow", Aurélien Géron, O'Reilly, 2017



- ► [HOML]→ udtales (Brian) Holm!
- ► [HOML] i ny version, forår 2019, som ikke bruges.
- Plus yderligere materiale (brug links i BB).
- ▶ NB: ITMAL helt nyt kursus; fejl og mangler påpeges!

Læringsmål

Når kurset er afsluttet forventes det at den studerende kan:

- Gengive udvalgt machine learning historie og teori, og dettes betydning for praktisk anvendelse.
- Redegøre hardwares betydning for machine learning algoritmer.
- Anvende udvalgte machine learning teknikker i praktiske opgaver og projekter.
- Anvende udvalgte kodebiblioteker (frameworks) og værktøjer til machine learning.
- Beskrive betydningen af data kvalitet i machine learning, samt anvende udvalgte data-behandlingsteknikker.
- ▶ **Sammenligne og vurdere** forskellige algoritmer og teknikkers anvendelighed i forbindelse med praktiske projekter.
- ▶ Diskutere litteratur om machine learning og vurdere materialets teoretiske og praktiske anvendelses muligheder.

Eksamen

Prøveform

Aflevering og godkendelse af alle journaler.

Bedømmelse

Godkendt/lkke godkendt, ingen censur.

Forudsætninger for prøvedeltagelse

For at kunne bestå kurset skal der i løbet af semesteret være afleveret et antal obligatoriske opgaver. Der vil være deadlines for afleveringen af de enkelte opgaver.

Bemærkninger

 Beståelsen af kurset sker på baggrund af én samlet vurdering af de afleverede opgaver, hvor der vil blive lagt vægt på, om den studerende opfylder punkterne i kvalifikationsbeskrivelsen. Bedømmelsen foretages kun af eksaminator (underviser).

Reeksamen

Næste ordinære eksamen. Samme procedure som ved den ordinære eksamen.
 Der skal afleveres nye opgaver til eksaminationen.

ITMAL Nomenklatur

```
[HOML]: Hands-On Machine Learning bog, aka (B.)Holm.
```

[GITHOML]: Git repository for [HOML].

[GITMAL]: Git repository for ITMAL kursus opgaver, opdater for hver ny lektion!

[G]: ITMAL gruppe, med tre studerende, (evt. fire).

[SG]: ITMAL super-gruppe, ved nogle af opgaverne.

[J1]: Journal 1 osv. (J2/J3).

[L01]: Lektion 1 osv.

NOTE: se fuld liste på 'BB | General | Nomenclature'.

Journalaflevringer: J1, J2 og J3

- J1: Q-Opgavesæt (jupyter notebooks).
- J2: Q-Opgavesæt (jupyter notebooks).
- J3: Mini-projekt:
 - For the final journal, you must design and implement a full machine learning system. You have relative free hands...

Criterions (extract):

- Data must be split in a training-test set...
- Your machine learning algorithm must be described in depth...
- The system must be evaluated via a suitable performance metric-..

NOTE₀: Afleveringsformat frit (PDF, .ipynb, etc.). NOTE₁: J3 vil blive specificeret på BB, med projektforslag. NOTE₂: J3 konflikt med BA projekter?

Syllabus

- L01: Intro.
- L02: End-to-end demo.
- LO3: Classification.
- L04: Training.
- LO5: Regularization and Searching.
- LO6: Reverse engineering of Learning.
- L07: Breaking the curse of dimensionality.
- L08: Deep learning I.
- L09: Adverserial examples.
- L10: Deep learning II.
- L11: Frameworks and Hardware + J3 Project.
- L12: J3 Project (until L16).

END OF PART I/BEGIN OF PART II



- Python is an interpreted high-level programming language for general-purpose programming. Created by Guido van Rossum and first released in 1991, Python has a design philosophy that emphasizes code readability, notably using significant whitespace. It provides constructs that enable clear programming on both small and large scales.
- Python features a dynamic type system and automatic memory management. It supports multiple programming paradigms, including object-oriented, imperative, functional and procedural, and has a large and comprehensive standard library.
- Python interpreters are available for many operating systems.





Anaconda and Jupyter Jupyter Introduction

- ► Anaconda: a python distribution [https://www.anaconda.com].
- Jupyter notebook: interactive python development environment (GUI IDE), distributed with the Anaconda package.
- Jupyter is an anagram of: Julia, Python, and R
- Jupyter notebook method:
 - √ polyglot environment, mixing source code, markdown test and formulas (LaTeX),
 - √ interactive trial-and-error environment,
 - ÷ not good at source-code level debugging.
- Other IDE's:
 - Spyder (Anaconda),
 - VSCode (Microsoft).
 - and many others...

Scikit-learn Introduction

- Scikit-learn: a page/site for machine Learning in python.
- ▶ http://scikit-learn.org
- ▶ git@github.com:scikit-learn/scikit-learn.git



Classification

Identifying to which category an object belongs to.

Applications: Spam detection, Image recognition.

Algorithms: SVM, nearest neighbors,

Regression

Predicting a continuous-valued attribute associated with an object.

Applications: Drug response, Stock prices.

Algorithms: SVR, ridge regression,
Lasso, ... — Examples

Clustering

Automatic grouping of similar objects into sets.

Applications: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, mean-shift, ... — Examples

Vores videnskabelige framework

Sat sammen...









Gode hjælpe og dokumentations-systemer..

Alternativer kunne være...

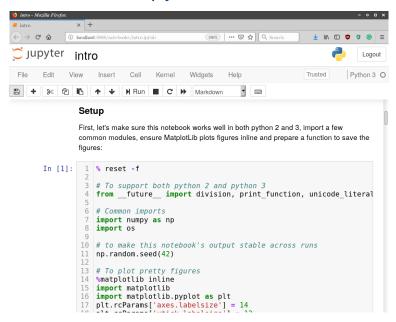








Anaconda and Jupyter Demo



Anaconda and Jupyter Demo

Highlights...

- Polyglot miljø:
 - lidt ala Matlab IDE,
 - markdown (HTML+LaTeX)-og-Python-i-een = polyglot,
 - alt kører i browser, lokalt eller på server.
- Quickstart:
 - åbn via http://localhost:8888 (efter launch),
 - ENTER på celle: editer celle,
 - CTRL+ENTER: kør celle.
- ► Magics:
 - nulstil vars: % reset -f.
 - ▶ inline plots: % matplotlib inline.
- ► Hints
 - Pas på globale vars (igen scopes ml. .ipynb celler),
 - Brug menu 'Help' og find shortcuts i 'open command palette'n,
 - ► Hvis du er C++ haj: alt er anderledes!

Machine learning taksonomi

- Læringstyper:
 - supervised (mest om dette i ITMAL),
 - unsupervised.
 - [semisupervised], [reinforced learning].
- Output klasser:
 - classification (ham/spam),
 - regression (F(x)=y),
- Læring via data:
 - batch læring (al data),
 - [inkrementel læring (on-the-fly)].
- Prediktions/generaliserings model:
 - model-based (pattern-detection, byg intern model),
 - [instance-based (lær al data udenad)],
- Typiske ML fejl klasser:
- ► for lidt trænings data (small-data, brug cross-validation),
 - sampling noise, sampling bias (ved manglende statificering),
 - outliers og dårlig data (i big-data),
 model og algoritme fejl: underfitting/overfitting.

Machine learning terminologi

- X, x: input data matrix og vektor,
- \mathbf{y} , \mathbf{y} : output data vektor og skalar,
 - θ : model parametre,
 - h: hypothesis funktion; typer af ML algos:

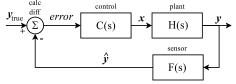
Bayes classifier, k-Nearest Neighbors, Linear Reg., Logistic Reg., SVM, Decision Trees, Random Forest, Neural Networks, k-Means, ...

- y_{true} : ground truth, til supervised learning, y_{pred} : predikteret værdi, aka \hat{y} ,
- attribut: data type, f.eks. salgspris,
- dog anvendes 'feature' typisk i stedet for
- feature: data attribut plus value, f.eks. $\lambda_{salgspris}$ =\$42, loss fun.: loss/cost/error funktion som minimeres i fitting, jo lavere jo bedre et fit er (objective fun.),
- score fun.: score/fitness/goodness funktion, jo højere jo bedre, bruges typisk til efter fit lossminimering, til eftervalidering.

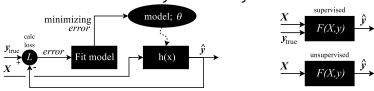
Supervised learning, blok diagram

Fra white-box til black-box

Almindelig white-box negativt feedback control block diagram, som for linear og tids-uafhængige lineære funktioner kan Laplace analyseres 'i det uendelige':



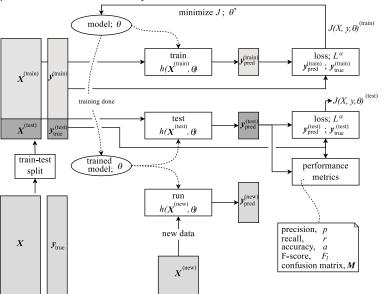
Supervised machine learning block diagram:



Valg af: Loss funktion, model/hypothesis funktion, that's is! (excl. hyperparametre). Alt er nu black-box.

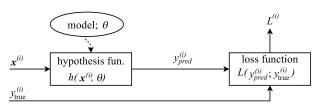
Supervised learning, blok diagram

Sneak-preview af 'the full monty'...



Q-Øvelse

ML supervised learning data flow model: single \mathbf{x} vektor and skalar y input...



med notation

 \mathbf{x} : data input vector; $\mathbf{x} = [x_1, x_2, \cdots, x_d]$,

 θ : model parametre,

h: hypothesis funktion, aka. ML algoritmen,

L: loss funktion, y_{true} : ground truth,

 y_{pred} : predikteret værdi for y, aka \hat{y}

med x havende dimensionalitet d... mere om denne i L02.

Q-Øvelse

Opstart med Python, Scikit-learn og lidt matematik...

- ▶ Jupyter notebook: intro.ipynb [GITMAL].
- ML Algoritmer:
 - mange forskellige ML algoritmer, vi går pt. ikke i detalien.
 - for denne opgave:
 - Linear Regression.
 - k-Nearest Neighbors.
 - lad være med at drukne i dem nu (fokuserer på det overordnede ML flow).
- ► Scikit-learn fit-predict interface
- Scores og Loss funktioner
 - Loss: funktion, som ML algoritmen forsøger at minimere under fit.
 - Score: funktion, der fortæller noget om hvor godt et predict er.