

## MACHINE LEARNING

LESSON 1: Introduction

CARSTEN EIE FRIGAARD HENRIK DANIEL KJELDSEN





## Undervisere

Carsten Eie Frigaard:

kursusholder,

rum: E311,

email: cef@ase.au.dk

Henrik Daniel Kjeldsen:

kursusholder,

rum: E301,

email: hdk@ase.au.dk

Peter Ahrendt hjælpelærer,

rum: E308,

email: pah@ase.au.dk







## Litteratur

"Hands-On Machine Learning with Scikit-Learn and TensorFlow", Aurélien Géron, O'Reilly, 2017



- ► [HOML]→ udtales (Brian) Holm!
- ► [HOML] i ny version, forår 2019, som ikke bruges.
- Plus yderligere materiale (brug links i BB).
- ▶ NB: ITMAL helt nyt kursus; fejl og mangler påpeges!

# Læringsmål

Når kurset er afsluttet forventes det at den studerende kan:

- Gengive udvalgt machine learning historie og teori, og dettes betydning for praktisk anvendelse.
- Redegøre hardwares betydning for machine learning algoritmer.
- Anvende udvalgte machine learning teknikker i praktiske opgaver og projekter.
- Anvende udvalgte kodebiblioteker (frameworks) og værktøjer til machine learning.
- Beskrive betydningen af data kvalitet i machine learning, samt anvende udvalgte data-behandlingsteknikker.
- ▶ **Sammenligne og vurdere** forskellige algoritmer og teknikkers anvendelighed i forbindelse med praktiske projekter.
- ▶ Diskutere litteratur om machine learning og vurdere materialets teoretiske og praktiske anvendelses muligheder.

## Eksamen

#### Prøveform

Aflevering og godkendelse af alle journaler.

#### **Bedømmelse**

Godkendt/lkke godkendt, ingen censur.

## Forudsætninger for prøvedeltagelse

For at kunne bestå kurset skal der i løbet af semesteret være afleveret et antal obligatoriske opgaver. Der vil være deadlines for afleveringen af de enkelte opgaver.

### Bemærkninger

 Beståelsen af kurset sker på baggrund af én samlet vurdering af de afleverede opgaver, hvor der vil blive lagt vægt på, om den studerende opfylder punkterne i kvalifikationsbeskrivelsen. Bedømmelsen foretages kun af eksaminator (underviser).

#### Reeksamen

Næste ordinære eksamen. Samme procedure som ved den ordinære eksamen.
 Der skal afleveres nye opgaver til eksaminationen.

## Syllabus

#### Preliminary...

- L01: Intro.
- L02: End-to-end demo.
- L03: Classification.
- LO4: Training.
- LO5: Regularization and Searching.
- LO6: Reverse engineering of Learning.
- L07: Breaking the curse of dimensionality.
- L08: Deep learning I.
- L09: Adverserial examples.
- L10: Deep learning II.
- L11: Frameworks and Hardware + J3 Project.
- L12: J3 Project (until L16).

## ITMAL Nomenklatur

```
[HOML]: Hands-On Machine Learning bog, aka (B.)Holm.
```

```
[GITHOML]: Git repository for [HOML].
```

[GITMAL]: Git repository for ITMAL kursus opgaver, opdater for hver ny lektion!

[G]: ITMAL gruppe, med tre studerende, (evt. fire).

[SG]: ITMAL super-gruppe, ved nogle af opgaverne.

[J1]: Journal 1, osv. (J2/J3).

[L01]: Lektion 1, osv.

NOTE: se fuld liste på 'BB | General | Nomenclature'.

# Journalaflevringer: J1, J2 og J3

- J1: Q-Opgavesæt (jupyter notebooks).
- J2: Q-Opgavesæt (jupyter notebooks).
- J3: Mini-projekt:
  - For the final journal, you must design and implement a full machine learning system. You have relative free hands...

Criterions (extract):

- Data must be split in a training-test set...
- Your machine learning algorithm must be described in depth...
- The system must be evaluated via a suitable performance metric-..

NOTE<sub>0</sub>: Afleveringsformat frit (PDF, .ipynb, etc.). NOTE<sub>1</sub>: J3 vil blive specificeret på BB, med projektforslag. NOTE<sub>2</sub>: J3 konflikt med BA projekter?

# END Kursus intro/BEGIN ML intro





- Python is an interpreted high-level programming language for general-purpose programming. Created by Guido van Rossum and first released in 1991, Python has a design philosophy that emphasizes code readability, notably using significant whitespace. It provides constructs that enable clear programming on both small and large scales.
- Python features a dynamic type system and automatic memory management. It supports multiple programming paradigms, including object-oriented, imperative, functional and procedural, and has a large and comprehensive standard library.
- Python interpreters are available for many operating systems.





# Anaconda and Jupyter Jupyter Introduction

- ► Anaconda: a python distribution [https://www.anaconda.com].
- Jupyter notebook: interactive python development environment (GUI IDE), distributed with the Anaconda package.
- Jupyter is an anagram of: Julia, Python, and R
- Jupyter notebook method:
  - √ polyglot environment, mixing source code, markdown test and formulas (LaTeX),
  - √ interactive trial-and-error environment,
  - ÷ not good at source-code level debugging.
- Other IDE's:
  - Spyder (Anaconda),
  - VSCode (Microsoft).
  - and many others...

## Scikit-learn Introduction

- Scikit-learn: a page/site for machine Learning in python.
- ▶ http://scikit-learn.org
- ▶ git@github.com:scikit-learn/scikit-learn.git



#### Classification

Identifying to which category an object belongs to.

**Applications**: Spam detection, Image recognition.

Algorithms: SVM, nearest neighbors,

#### Regression

Predicting a continuous-valued attribute associated with an object.

**Applications**: Drug response, Stock prices.

Algorithms: SVR, ridge regression,
Lasso, ... — Examples

#### Clustering

Automatic grouping of similar objects into sets.

**Applications**: Customer segmentation, Grouping experiment outcomes

Algorithms: k-Means, spectral clustering, mean-shift, ... — Examples

# Vores videnskabelige framework

Sat sammen...









Gode hjælpe og dokumentations-systemer..

Alternativer kunne være...

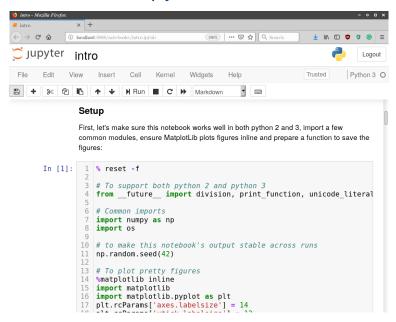








# Anaconda and Jupyter Demo



# Anaconda and Jupyter Demo: Highlights...

- Polyglot miljø:
  - lidt ala Matlab IDE,
  - markdown (HTML+LaTeX)-og-Python-i-een = polyglot,
  - alt kører i browser, lokalt eller på server.
- Quickstart:
  - åbn via http://localhost:8888 (efter launch).
    - ENTER på celle: editer celle,
    - CTRL+ENTER: kør celle.
    - SHIFT+TAB: hjælp på funktion.
- ► Magics:
  - nulstil vars: % reset -f,
  - ▶ inline plots: % matplotlib inline.
- ► Hints
  - Pas på globale vars (igen scopes ml. .ipynb celler),
  - Brug menu 'Help' og find shortcuts i 'open command palette'n,
  - Hvis du er C++ hai: alt er anderledes!

## Machine learning taksonomi

- Læringstyper:
  - supervised (mest om dette i ITMAL),
    - unsupervised.
  - [semisupervised], [reinforced learning].
- Output klasser:
  - classification (ham/spam),
  - regression (h(x) = y),
- Læring via data:
  - batch læring (al data),
    - [inkrementel læring (on-the-fly)].
- Prediktions/generaliserings model:
- model-based (pattern-detection, byg intern model),
  - [instance-based (lær al data udenad)],
- Typiske ML fejl klasser:
- ► for lidt trænings data (small-data, brug cross-validation),
  - sampling noise, sampling bias (ved manglende statificering),
    - outliers og dårlig data (i big-data),
       model og algoritme fejl: underfitting/overfitting.

# Machine learning terminologi

- X, x: input data matrix og vektor,
- **y**, y: output data vektor og skalar,
  - $\theta$ : model parametre,
  - h: hypothesis funktion; typer af ML algos:

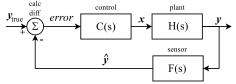
Bayes classifier, k-Nearest Neighbors, Linear Reg., Logistic Reg., SVM, Decision Trees, Random Forest, Neural Networks, k-Means, ...

- y<sub>true</sub>: ground truth, til supervised learning,
- $y_{\text{pred}}$ : predikteret værdi, aka  $\hat{y}$ ,
- attribut: data type, f.eks. salgspris, dog anvendes 'feature' typisk i stedet for attribut!
- feature: data attribut plus value, f.eks.  $\lambda_{\text{salgspris}} = \$42$ ,
- loss fun.: loss/cost/error/objective funktion, som minimeres i fitting, jo lavere jo bedre et fit,
- score fun.: score/fitness/goodness funktion, jo højere jo bedre, bruges typisk efter fit-minimeringingen
  - til model inspektion og eftervalidering.

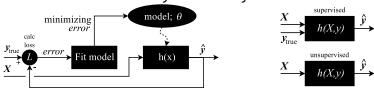
# Supervised learning, blok diagram

#### Fra white-box til black-box

Almindelig white-box negativt feedback control block diagram, som for linear og tids-uafhængige lineære funktioner kan Laplace analyseres 'i det uendelige':



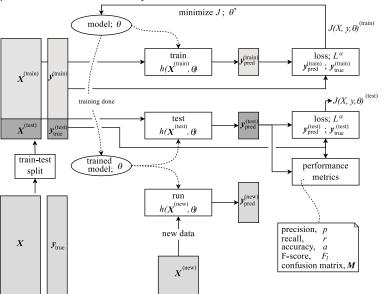
Supervised machine learning block diagram:



Valg af: Loss funktion, model/hypothesis funktion, that's is! (excl. hyperparametre). Alt er nu black-box.

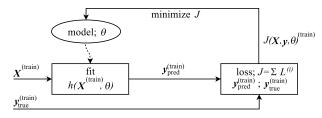
# Supervised learning, blok diagram

Sneak-preview af 'the full monty'...



## Q-Øvelse

ML supervised learning data flow model: Training (fit).



**X**<sup>(train)</sup> : trænings matrix input data,

 $\mathbf{x}^{(\text{train})}$  : data input vector;  $\mathbf{x} = [x_1, x_2, \cdots, x_d]$ ,

 $\mathbf{y}_{\text{true}}^{(\text{train})}$  : trænings input ground truth vektor,

 $\mathbf{y}_{\text{pred}}^{(\text{train})}$ : predikteret værdi for y, aka  $\hat{y}$ 

 $\theta$ : model parametre,

h: hypothesis funktion, aka. ML algoritmen,

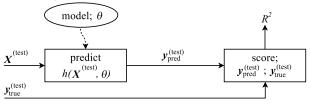
 $L^{(i)}$ : loss funktion (indivduel),  $L^{(i)}(y_{\text{pred}}^{(i)}, y_{\text{true}}^{(i)})$ 

J: loss funktion (summeret),  $J = \frac{1}{n} \sum_{i} L^{(i)}$ .

med  $\mathbf{x}$  havende dimensionalitet d... mere om denne og loss funktioner i L02.

## Q-Øvelse

#### ML supervised learning data flow model: Prediction



#### Øvelse:

- træn en linær regressions model, (Scikit-learn fit-predict interface),
- gå i detajen med R<sup>2</sup> score funktionen,
   (NOTE: test data er lig train data for denne øvelse),
- check k-Nearest Neighbors modelen ud på data, sammenlign kNN-score med linær regression-score.